

Fejlesztő dokumentáció

- ARCH

- Funkciója: absztrakciós szintet biztosít egy archív fájl kezeléséhez
 - Az **ARCH** struktúra
 - **FILE*** **f** tartalmazza a címét az archív fájlnek
 - **char*** **key** tartalmazza a XOR vagy XNOR titkosítás kulcsát. Abban az esetben, ha a pointer értéke 0, akkor nincs titkosítás
 - **bool** **xor** mutatja, hogy az archív fájlhoz XOR vagy XNOR titkosítás alkalmazandó, amennyiben van a fájlban titkosítás beállítva
 - **node*** **root** az archív faszerű könyvtárrendszerének a gyökere. Ebből ágaznak ki a levelek (fájlok) és csomópontok (könyvtárak)
 - **node*** **sel** pointer tárolja a fenti fának azon elememét, amelyet kiválasztottak az **archfseek(ARCH* a, char* path)** függvény segítségével
 - **size_t** **selpos** a fent említett kiválasztott fájlban a jelenlegi pozíciót mutatja
 - Az előbbi 2 adat segítségével az int **archfread(ARCH* a, char* buff, int n)** függvény segítségével olvashatunk egy kiválasztott fájl végéig amelyet a bool **archfeof(ARCH* a)** függvénnyel ellenőrizhetünk. Az **archfeof()** függvény a fájlhoz tartozó **node** struktúrában tárolt mérete és a **size_t selpos** alapján tudja meghatározni, hogy van-e még fennmaradó olvasandó bájt. Az **n** a kért bájtok száma, a **char*** a tömb ahova írja a kiolvasott bájtokat, és az eredménye a valóban kiolvasott bájtok száma
 - Minden más függvény amely írás/olvasás műveletet végez az archívban elmenti a **FILE*** jelenlegi pozícióját és a függvény végén visszaállítja, azért, hogy az **archfseek()** **archfreed()** és **archfeof()** függvények viselkedése ne sérüljön
 - az **ARCH* archparse(char* path, char* key)** függvény feladata, hogy beolvassa az archív fájlt. Az első paramétere tehát elérési út az archívhoz, a második paramétere a titkosítási kulcs, amelyre csak akkor van szükség, ha a be van állítva titkosítás. A titkosítás fajtáját a fájl bitmezőjéből olvassa majd ki. Ennek módosítására vagy megadására a későbbiekben elmagyarázott függvényeknél van lehetőség
 - Az archív fájl első bájtja **bitmező**. Az LSB bit, ha 1, akkor titkosítva van az állomány. Amennyiben van titkosítás, akkor 2-es helyiértékű bit, ha 1, akkor XOR titkosítva van az állomány, különben XNOR titkosítva. Sajnos, egyelőre a többi bit kihasználatlan

- A bitmező állítható az **archsetbitfield(ARCH* a, bool crypt, bool xor)** procedúrával, a paraméterek alapján összeállítja és az archív elejére írja a megfelelő bájtot
- A bitmező bitszintű olvasására az AND maszkokat alkalmazó **bool getbit(char field, int i)** és a **void setbit(char* field, int i)** függvények valók. Ezek az util modulban találhatók
- Amennyiben a bitmező alapján titkosítva van az állomány és nullpointert kap a kulcs paraméterébe az **archparse()**, vagy a kulcs mérete nincs meg legalább 1 karakter, akkor null címmel visszatér
- Az **ARCH* archcreate(char* char* path, char* key, bool xor)** függvén feladata, hogy létrehozzon egy megadott elérési úton egy archívot, és amennyiben titkosítva kérjük, akkor a kulcsot és a titkosítás módját is paraméterként meg kell adni
- Az **archfincorp(ARCH* a, char* fpath)** függvény adott útvonalon levő fájlt az archív végére ír
- Az **archfincorp_e(ARCH* a, char* fpath, char* tpath)** függvény az adott útvonalon levő fájlt az archívon belül másik megadott útvonalra helyezi
- Az **archdincorp(ARCH* a, char* path)** és **archdincorp_e(ARCH* a, char* fpath, char* tpath)** viselkedések pedig ugyanazt vállalják mint a fenti két függvény, csak ők mappákkal működnek, és rekurzívan felderítik a kiadott mappát: a teljes megadott almapparendszer betárolásra kerül, nem csak a közvetlen gyerekek
- Az **bool archrdincorp(ARCH* a, node* n, char* path, char* apath)** egy rekurzív procedúra amelyet az előző két viselkedés hív. A node paraméter megfelel a path elérési úton levő mappának, illetve az apath az archívon belüli elérési útja. Ezután felderítődnek a közvetlen gyermekei, a fájlok és mappák. A fájlokat beírja az archívba, úgy, hogy az **apath** végére írja a fájlnévet, illetve a fájlt is a **path** végéhez írt fájlnévről éri el. Az almappák pedig nyilván felderítendőek még. Ezért a függvény rekurzívan hívja önmagát. Amennyiben az adott almappa nem létezik még a mostani node gyermekei között, létrehozza a mappát, és hozzáírja az **apath** és **path** végére a mappa nevét, hiszen ezekkel a paraméterekkel kell rekurzívan meghívni megint a függvényt
- A **bool archforceappend(ARCH* a, char* path, char* apath, uint* fsz, size_t* pos)** viselkedést alkalmazza, az előző, elvégzi az archívhoz írást. A **path**-en megnyitja a fájlt, az **fsz**-be írja a méretét, a **pos**-ba, hogy hová kerül az archívon belül a fájl, és az **apath**-ot írja bele archívon belüli útvonalként. Azért kell, hogy a **pos** és **fsz** adatokat visszaadja az **archrdincorp()** függvénynek, mert annak szüksége van ezekre az adatokra, hogy tudja a regisztrálni a beírt fájlt a node fában
- Az archív formátuma egyszerű: az első bájt egy bitmező, és utána végig blokkok vannak. Egy blokk első 4 bájtja előjeletlen egész szám, amely a fájl

méretét tárolja. A fájl után közvetlenül a blokk végén lezáró nullával végződő, a mappa gyökeréhez mért relatív útvonal szerepel. Utána jön a következő blokk

- Egy ilyen blokk olvasására van az **archreadblock(ARCH* a)** viselkedés
- A **bool archsetcrypto(ARCH* a, bool on, char* key, bool xor)** feladata, hogy elbírálja, hogy a kért titkosítási kérelem végrehajtható-e. Ellenőrzi, hogyha titkosításra kap felkérést, akkor van-e már titkosítva az állomány, vagy ha dekódolásra kap felkérést, akkor nem volt-e az archív alapból dekódolt. Ha pedig nincs ilyen baj, akkor az alábbi függvényt alkalmazza:
- Az **archcryptthrough(ARCH* a)** procedúra feladata, hogy titkosítás bekapcsolása vagy kikapcsolása esetén végrehajtsa a XOR vagy XNOR kódolást minden egyes fájlra. Ez egy szimmetrikus kódoló/dekódoló függvény, hiszen a XOR és XNOR is szimmetrikus kriptó
- A **bool archextract(ARCH* a, char* fpath, char* tpath)** függvény feladata, hogy adott gyökérhez mért útvonalon levő fájlt kicsomagolja a megadott útvonalra. Mivel egy könyvtárat teljes mappaszerkezete kicsomagolandó, ezért ezt a kicsomagolást is rekurzív viselkedésnek adja tovább:
- A **void archreextract(ARCH* a, node* n, char* p)** viselkedés kicsomagolja egy adott könyvtár közvetlen gyermekeit, és rekurzívan meghívja magát a közvetlen könyvtárgyermekeit reprezentáló **node**-okon. A fájlokat és a mappákat is létrehozza, amelyek még nem léteznek
- Az **archrelease(ARCH* a)** viselkedés a release függvények családjába tartozik, amelyek adott struktúra heap memóriájának felszabadítására vannak. Ez egy rekurzív felszabadító függvény, hiszen egy egész faszerkezetet fel kell szabadítania
- Az **archreader(ARCH* a, char* buff, int n, size_t* pos)** és **archwriter(ARCH* a, char* buff, int n, size_t* pos)** függvények feladata, hogy adatot olvassanak az archívból. Minden olyan magasabb szintű függvény, amit eddig felsoroltam ezeken keresztül ír vagy olvas, azért, mert automatikusan végrehajtja olvasáskor/íráskor a titkosítási műveleteket amennyiben szükséges
- **crypto**
 - Tartalmazza a **xorcrypt(char* buff, uint bsz, char* key, int ksz, size_t* pos)** és **xnorcrypt(char* buff, uint bsz, char* key, int ksz, size_t* pos)** függvényeket, amelyek feladata egy adott buffer megfelelő letitkosítása a kulccsal. Az utolsó **size_t* pos** paramétere hangsúlyos. Ennek 0 a kezdőértéke és a függvény módosítja címen keresztül. Erre azért van szüksége, mert egy nagyobb fájlra a titkosítási kulcsot úgy lehet alkalmazni, hogy ismételjük azt, maradékos osztás segítségével. A pontos illesztéshez viszont muszáj tudni, hogy az adott fájl melyik pozíciójánál járunk éppen
 - Az egyetlen viselkedés amely ezeket a függvényeket alkalmazza értelemszerűen az **archreader()** és **archwriter()**

- unordered_map

- Az `unordered_map` egy hasítótábla
- `node** buckets` egy pointer tömb, és mindegyik pointer egy láncolt lista elejére mutat, amelyekben azon `node` elemek kerülnek eltárolásra, amelyeknek ugyanaz a `hash` érték jutott
- a vödrök számát az `uint` bsz változó tárolja
- az `uint sz` a vödrökben összesen tárolt elemek számát mutatja
- `rollhash32(char* key, int b, int m)` egy 32 bites hash értéket generál sztring paraméter alapján. Nagy szavakban úgy kezeli a sztringet, mint egy 256-os számrendszerbeli modulált számot, amelyben minden számjegyet (karaktert) egy adott kitevős együtthatóval szorzunk. A bázis (radix) és a modulátor paraméterként meghatározható
- A `hash` értéket maradékosan osztva a vödrök számával megkapjuk azt, hogy melyik láncolt listába kerüljön elhelyezésre az adott kulcs
- Természetesen a bázis és a modulátorok prímszámok. Olyan prímszámok lettek meghatározva, amelyek nem engedik, hogy a `hash` érték túlcsoorduljon. Emiatt a `uint hashof(char* key)` függvény egy absztrakció a `rollhash32()` függvény felett, amely amely az előre meghatározott prímekkel hívja az előbbi függvényt
- Az `unordered_map* umcreate()` függvény a hasítótáblát hozza létre, az `umrelease(unordered_map* um)` pedig felszabadítja. Az `umrelease()` függvény paramétereként egy felszabadító függvény adható meg, amely arra van, hogy a hasítótáblának a `node` struktúráiban tárolt `void* data` által hivatkozott memóriát kezelje ahogy kell
- Az `node* umput(unordered_map* um, char* key, void* dat)` művelettel adott kulcsban kérhető egy generikus adat eltárolása (`void* dat`). A létrehozott `node` címét adja vissza
- Az `node* umget(unordered_map* um, char* key)` művelet az `umput()` ellentettje, adott kulcsban levő `node` kikérése való. Ha nem létezik nullpointert ad vissza
- Az `void umresize(unordered_map* um)` viselkedés feladata, hogy megduplázza a hashmap vödreinek a számát, és újra elossza azokat a megváltozott vödörszám és a hash értékek alapján. Ez a viselkedés akkor hívódik meg, amikor az `umput()` észleli, hogy a tárolt elemek száma már a vödrök számának kétszerese. Emiatt a `get` és `put` műveletek maradnak konstans probabilisztikus idejűek
- A `node** umgetbucket(unordered_map* um, char* key, uint* hash)` visszaadja annak a vödör pointerének a pointerét, amelybe a paraméterként megadott kulcsnak kerülnie kell, emellett pedig kipakolja az általa generált hash értéket a `hash` paraméterbe

- A **node* buinsert(void* dat, char* key, uint hash, node** bucket)** feladata, hogy a kiszámított vödörben levő láncolt listában elhelyezze a megadott kulcsot (és a hozzá tartozó **void* data** elemet). A létrehozott elemet amennyiben nem létezik visszaadja, ellenkező esetben nullpointerrel tér vissza
- A **node* busearch(node* bucket, char* key)** feladata, hogy az **umgetbucket()** által meghatározott vödörben kikeresse az adott **node** elem címét. Amennyiben nem található, 0 címmel tér vissza
- A **void umwalk(unordered_map* um, void (*iterator)(node* i))** viselkedés végigiterál az összes láncolt listán a **void llwalk(node* n, void (*iterator)(node* i))** viselkedés segítségével, és mindegyikhez meghívja a paraméterül adott függvényt
- Ennél fejlettebb módja a tábla elemein való végigfutására az **IT** absztrakció, amelynek egy példányát adja vissza az **IT* umiterator(unordered_map* um)** függvény
- **IT**
 - Az absztrakció feladata, hogy egyszerűen végig lehessen iterálni egy hasítótábla elemein
 - Az **IT* itcreate(node** buckets, int bsz)** függvényben megadandóak a vödrök és azoknak a száma, ez elegendő a bejáráshoz
 - A **node* itnext(IT* i)** függvény visszaadja a hasítótábla következő node elemének a címét, ha meg nincs következő, akkor 0-át ad vissza folyamatosan
- **node**
 - Általános láncolt lista elem
 - Ugyanakkor elkerülhetetlen volt, hogy összeemelegedjen szorosabban a hashmap-pel is, így nem csak következő elemet (**struct node* next**) és generikus adatot tárol (**void* data**), hanem hasítótábla kulcsot: **char* key**, illetve **uint hash** értéket is
- **Info**
 - Az **info** struktúra összefog mindent egy csomagban, amit egyetlen **node** elemnek tárolnia kell. Ez az a struktúra tehát, amelyek példányaira mutatnak a **node void* data** pointeri
 - **bool file** mutatja, hogy az adott elem fájl vagy mappa
 - Amennyiben mappa, akkor az **unordered_map* um** pointer tárolja a közvetlen gyerekeit
 - Amennyiben fájl, akkor a **size_t addr** tárolja a fájl pozícióját az archívban. És a **size_t fsz** tárolja a fájl méretét
- **Util**
 - Az **util** modul nagyon fontos segédfüggvényeket tartalmaz
 - Ide tartozik a fentebb már említett **bool getbit(char field, int i)** és **void setbit(char* field, int i)** viselkedés, amely a bitmező olvasására való

- Az archívban tárolt fájlok elérési útjai alapján a program fájlok és mappák faszerű hierarchiáját képezi le. Ennek a magja az egységnyi elem, a **node**, amelynek a meghatározó tulajdonságait a **void* data** által mutatott **info** objektum tartalmazza. Amennyiben ez egy mappa, akkor újabb **node** elemeket tartalmazó hasítótáblához jutunk. Ezen fában való közlekedés, és a fa könnyed szerkesztésére ide helyeztem el a segédfüggvényeket. A **size_t nfsz()**, **bool nfile(node* n)**, **size_t naddr(node* n)**, **unordered_map* num(node* n)** függvények arra valók, hogy gyorsan le lehessen kérni a **void* data** által mutatott **info** objektumból a valójában **node**-ot jellemző tulajdonságokat
- Ezeken kívül számos függvény ezen **node** fa menedzsmentjét intézik:
- **node* nsub(node* n)** függvény például lekéri a paraméterül kapott **node** ből a megadott kulccsal rendelkező gyermek **node** objektum címét a hozzá tartozó hasítótáblából, már amennyiben természetesen ez egy mappa. Ha nem létezik a gyermek, akkor 0 címmel tér vissza
- az **ncdsub(node* n, char* key)** és **ncfsub(node* n, size_t addr, size_t fsz)** függvények arra valók, hogy ha a paraméterül kapott **node** mappa, akkor ha nem létezik a paraméterül kapott kulcsú gyermeke, akkor azt létrehozza. Az **ncdsub()** almappát, az **ncfsub()** alfájlt szűr be. A sikeresen beszűrt elem címét visszaadja
- az **nmakepath(node* n, char* path)** függvény feladata, hogy a megadott **node** tól kezdve létrehozza a megadott elérési utat végig. A legutolsó útvonalkomponenshez létrehozott **node** címét adja eredményül
- az **node* nrmakepath(node* n, char** mat, uint i, uint sz)** függvény feladata, hogy mindig a teljes létrehozandó útvonal következő komponensét létrehozza a megfelelő **node** közvetlen gyermekeként. Az előbbi függvény ezt használja, rekurzív függvény. **char** mat** a feldarabolt **char* path** paraméter, **uint i** a feldolgozandó darab indexe, **uint sz** az összes komponens száma
- A **node* nfind(node* n, uint i, uint sz, char** mat)** függvény feladata, hogy kikeresse a megadott útvonalon levő **node** címét, a paraméterül adott **node**-tól kezdve. A **char** mat**, **uint i**, **uint sz** a feldarabolt útvonalkomponensek tömbje, a jelenlegi index a tömbben, és a tömb teljes mérete, respektíven
- **uint fgetsz(FILE* f)** függvény visszaadja a paraméterül adott fájl méretét
- az **int mkd(const char* dir)** függvény létrehozza a megadott útvonalon a mappát, amennyiben csak egy létező mappa közvetlen gyermekeként kell csak létrehozni. Amennyiben a fordítás POSIX rendszer, akkor az **unistd.h** fejléc **mkdir()** függvényét hívja, amennyiben Windows, akkor a **direct.h** fejlécben levő **_mkdir()** függvényt hívja
- az **char* _strcat(char* to, char* str)** függvény heap-en hozza létre az összeagglutinált sztringet, de végül sajnos semmi sem használja
- a **char* combine(char* path, char* with)** feladata, hogy elérési út szeparátorral összekösse a két útvonalkomponenst

- a **int* kmptbl(char* pattern)** függvény létrehozza kmp mintaillesztő algoritmus által használt prefixtáblázatot, egy adott mintához.
- A **char* kmpfi(int* tbl, char* str, char* pat)** függvény paraméterül kap egy **kmptbl()** függvény által generált prefixtáblázatot, és visszaadja a minta legelső előfordulásának pointerét egy szövegen belül. Tulajdonképpen **strtok()**-ot helyettesíti, amely nem módosítja az eredeti sztringet. A függvény fájlok keresésére lett volna kitalálva, csak mivel a specifikációban nem szerepelt és idő hiányában voltam, végül ez a függvény sem került használatra
- **char** ppsplit(char* path, uint* splitsz)** függvény feladata, hogy feldaraboljon egy útvonalat komponenseire. Az **ssrelease(char** mat, int sz)** a megfelelő procedúra a felszabadításra
- A **char* ppnext(char* from)** a **ppsplit()** által használt függvény, mely visszaadja egy sztring pozíciótól a legelső útvonalszeparátor előfordulásának pointerét, különben ha nem létezik akkor 0 címmel tér vissza
- A **char* lastcomp(char* path)** függvény feladata, hogy visszaadjon egy pointert arra a karakterre az útvonalon, amely a legutolsó útvonalszeparátor után található. Amennyiben ez nem létezik, akkor ugyanazt a pointert adja vissza.
- A **char* cwd(char* buff, size_t max)** függvény feladata, hogy visszaadja a program futásának mappáját. Ez megint platformdependens függvény, POSIX rendszeren az **unistd.h**-ban levő **getcwd()** függvényt hívja, különben Windows-on az ennek megfelelő **direct.h** fejlécben levő **_getcwd()** függvényt hívja
- **NIT**
 - A **NIT** absztrakciót biztosít az IT struktúra felett, a feladata egy mappának minősülő **node** struktúra közvetlen gyerekeinek az enumerációja
 - A **NIT** is biztosítja ugyanazt a **node* nitnext(NIT* n)** operációt, amellyel a soron következő **node** gyermek címe kivehető, illetve ha nincs több gyermek akkor 0-t ad vissza
 - A **NIT** mindössze egy egyszerű wrapper, amely az **unordered_map* num(node* n)** függvénnyel kinyeri a node-hoz tartozó hasítótáblát, és az ahhoz visszaadott IT objektum által adott eredményeket közvetíti
- **dirmapper**
 - A **dirmapper** tartalmaz egy **SUBS** struktúrát amely lényegében egy vektort (dinamikus tömböt) tartalmaz fájlokhoz és mappákhoz, amelyek közvetlen gyermekei egy adott mappának. Ezt adja vissza a **SUBS* subsof(char* path)** függvény adott útvonalon levő mappához
 - **subsdirs(SUBS* s)** és **subfiles(SUBS* s)** függvények mindössze getterei a **SUBS** struktúrának
 - A **subsof()** függvény platformdependens. A POSIX implementáció viszonylag egyszerűbb, a **dirent.h** fejlécben levő struktúrák és függvények segítségével működik, míg a Win32 API-s implementáció picit rondább struktúrákkal csinálja meg teljesen ugyanazt. Valójában az egész projektben ez az egyetlen

forrás amit nem én írtam meg, hanem egy C++-os forrást alakítottam át úgy, hogy használható legyen C nyelven. Ebben nyilvánvalóan semmi nehézség nem volt, hiszen a Win32 API alából C API, illetve az eredeti forrásban nem volt szükség sztring-nél összetettebb osztályok alkalmazására

- **Egyéb megjegyzések:** ahol egyébként nincs specifikálva, a bool visszatérési érték jelzi a függvények sikerességét, ez egy nagyon gyakran használt séma a projektben. A xor és xnor titkosítás szép így, de mivel a kulcs hossza nagy eséllyel nem ér fel a bemeneti fájlok méretével ezért ismételni kell, ez pedig így könnyen feltörhetővé teszi. XOR-nál például a 0 bitek folyamatosan reflektálják a kulcsnak a bitjeit, vagyis látszik a fájlban az ismétlődő kulcs. One Time Pad illetve AES titkosítást egyelőre nem támogat a program sajnos